



Bölüm 5: Dizge Algoritmaları

Algoritmalar



Dizge Algoritmaları

- Metinlerle dolu bir dünyada yaşıyoruz.
- E-postalar, mesajlar, sosyal medya paylaşımları, haber metinleri...
- Bilgisayarlarımızda her gün sayısız metinle karşılaşırız.
- Peki, bu metinler nasıl düzenlenir ve analiz edilir?
- Dizge (String) algoritmaları,
 - metinlerde arama,
 - değiştirme,
 - karşılaştırma gibi işlemleri gerçekleştirir.



Dizge Algoritmalarının Çeşitleri

- Farklı string algoritmaları, farklı çalışma prensiplerine sahiptir.
- Brute Force (Zorlama) Arama:
 - Metnin tamamını tek tek tarayarak arama yapar (basit ama yavaştır).
- Knuth-Morris-Pratt (KMP) Algoritması:
 - Arama paternindeki tekrarlardan faydalanarak daha hızlı arama yapar.
- Boyer-Moore Algoritması:
 - Arama paterninin sonundaki karakterlerden başlayarak arama yapar.
- Rabin-Karp Algoritması:
 - Metnin ve arama paterninin hash değerlerini karşılaştırarak arar.



String Naive Algoritması

- Bir metin içinde belirli bir örüntüyü (*pattern*) arayan basit bir algoritma.
- Naive (Saf) olarak adlandırılır çünkü basit bir yaklaşım kullanır.
- Ortalama ve en kötü durumda $O(m * n)$ zaman karmaşıklığına sahiptir.
 - (m: örüntü uzunluğu, n: metin uzunluğu)

İşleyiş



- Metindeki her konum için örüntünün ilk karakterinin eşleşip eşleşmediğini kontrol edilir.
- Eşleşen karakterlerin tümü için örüntünün tam olarak eşleşip eşleşmediğini kontrol edilir.
 - Eşleşme Durumu: eşleşme pozisyonu rapor edilir.
 - Eşleşmeme Durumu: sonraki pozisyonlar kontrol edilir.
- Metindeki tüm konumlar için adımlar tekrarlanır.

Brute Force - Naive



HELLO WORLD



Brute Force - Naive

LO
HELLO WORLD



Brute Force - Naive





Brute Force - Naive





Brute Force - Naive





Brute Force - Naive





Brute Force - Naive





Brute Force - Naive





Brute Force - Naive





Brute Force - Naive







Knuth-Morris-Pratt (KMP) Algoritması

- Bir metin içinde belirli bir örüntüyü bulmak için kullanılır.
- *Donald Knuth, Vaughan Pratt* ve *James H. Morris* tarafından geliştirilmiştir.
- Ortalama ve en kötü durumda $O(m + n)$ zaman karmaşıklığına sahiptir.
 - (m: örüntü uzunluğu, n: metin uzunluğu)



İşleyiş

- Ön İşleme: Örüntü içindeki her karakter için,
 - eşleşme durumunda geri dönecek pozisyonları belirleyen,
 - en uzun önek-suffix eşleşmesini bulan bir tablo oluşturulur.
- Örüntü Arama: Metin içinde arama yapılırken,
 - örüntü ile eşleşmeyen karakterlerde geri dönecek pozisyonlar,
 - tablodan elde edilen geri dönüş değerleri kullanılarak hesaplanır.
- Eşleşme Kontrolü: Eşleşen karakterlerin tümü için örüntünün tam olarak eşleşip eşleşmediği kontrol edilir.

Örnek




- Metin: "ababcababcabababd"
- Örüntü: "ababd"
- Örüntü Tablosu:
 - a: 0, b: 0, a: 1, b: 2, d: 0




Knuth Morris Pratt

- *Longest Proper Prefix*






Knuth Morris Pratt






Knuth Morris Pratt






Knuth Morris Pratt






Knuth Morris Pratt





Knuth Morris Pratt





Knuth Morris Pratt

Pattern	A	C	A	B	A	C	A	C	D
LPS	0	0	1	0	1	2	3		



Knuth Morris Pratt

Pattern	A	C	A	B	A	C	A	C	D
LPS	0	0	1	0	1	2	3	2	




Knuth Morris Pratt

Pattern	A	C	A	B	A	C	A	C	D
LPS	0	0	1	0	1	2	3	2	0



Knuth Morris Pratt







Boyer-Moore Algoritması

- Bir metin içinde belirli bir örüntüyü arar.
- *Robert S. Boyer* ve *J Strother Moore* tarafından geliştirilmiştir.
- Ortalama ve en kötü durumda $O(n/m)$ zaman karmaşıklığına sahiptir.
 - (n: metin uzunluğu, m: desen uzunluğu)

İşleyiş



- Ön İşleme: Örüntü içindeki her karakter için eşleşme durumunda geri dönülecek pozisyonları belirleyen bir tablo oluşturulur.
- Arama: Metin içinde örüntüyü ararken, eşleşmeyen karakterlerde tablodan yararlanarak geri dönülecek pozisyonlar hesaplanır.
- Eşleşme Kontrolü: Eşleşen karakterlerin tümü için örüntünün tam olarak eşleşip eşleşmediği kontrol edilir.
- Kötü Karakter Kaydırma Kuralı: Eşleşmeyen bir karakter varsa, örüntüdeki bu karakterin metindeki en sağdaki konumu baz alınarak kaydırma yapılır.
- İyi Sone Kuralı: Eşleşmeyen bir alt-dizgi varsa, örüntüdeki bu alt-dizginin metindeki en sağdaki konumu baz alınarak kaydırma yapılır.

Örnek



- Metin: "abccbaabccbaabcbcabbbababcabc"
- Desen: "abcbcabbbababcabc"
- Desen Tablosu:
 - a: 10, b: 8, c: 7
- Sonuç:
 - Pozisyon 12: "abcbcabbbababcabc"

Boyer Moore



H	E	L	L	O												
L	O		L	O	E	L	L	O		O		H	E	L	L	O

Boyer Moore



H	E	L	L	O															
L	O		L	O	E	L	L	O		O		H	E	L	L	O			

Boyer Moore



H	E	L	L	O															
L	O		L	O	E	L	L	O		O		H	E	L	L	O			

Boyer Moore



HELLO
LO LLOELLOHELLO




Couldn't match, move on

Boyer Moore



HELLO
LO L O E L L O O H E L L O

Boyer Moore



Boyer Moore



HELLO
LO LOELLO O HELLO

Boyer Moore



HELLO
LO LOELLO O HELLO

Boyer Moore



HELLO
LO LOELOLO OHELLO

Boyer Moore



HELLO
LO LOELOLO OHELLO

Boyer Moore



HELLO
LO LOELLO OHELLO

Boyer Moore



Couldn't match, move on

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO
LO LOELLO O HELLO

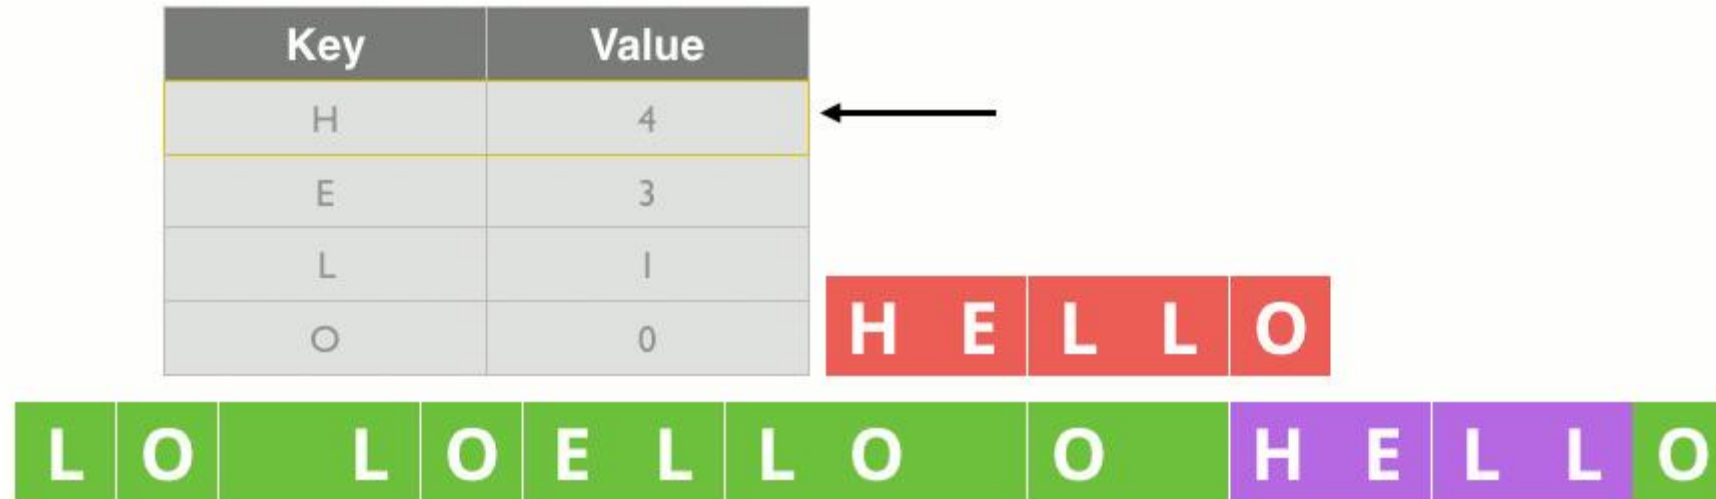
Boyer Moore



HELLO
LO LOELLOLO OHELLO



Boyer Moore



H is in skip table, skip 4

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO
LO L O E L L O O H E L L O

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO
LO LOELLOLO HELLO

Boyer Moore



HELLO

LOELLOHELLO

Boyer Moore



✓ H E L L O
L O L O E L L O O H E L L O





Rabin-Karp Algoritması

- Bir metin içinde belirli bir örüntüyü bulmak için kullanılır.
- *Michael O. Rabin* ve *Richard M. Karp* tarafından geliştirilmiştir.
- Ortalama ve en kötü durumda $O(n + m)$ zaman karmaşıklığına sahiptir.
 - (n: metin uzunluğu, m: örüntü uzunluğu)

İşleyiş



- Hash: Örüntü ve metin içindeki alt dizgelerin hash değerleri hesaplanır.
- Eşleşme Kontrolü: Hash değerleri eşleşen alt dizgeler karşılaştırılır.
- Doğrulama: Eşleşme olduğunda, karakter bazında doğrulanır.
- Kaydırma ve Yeniden Hesaplama: Eşleşme olmadığında, yeni bir alt dizge seçilir ve hash değeri yeniden hesaplanır.
- Tekrarlama: Tüm metin boyunca adımlar tekrarlanır.



Örnek

- Metin: "abracadabra"
- Örüntü: "cad"
- İşleyiş:
 - Hash Değerleri: Metin: "abr", Örüntü: "cad"
 - Eşleşme Kontrolü: Hash değerleri eşleşmez.
 - Kaydırma ve Yeniden Hesaplama: Yeni alt dizge seçilir: "bra"



Rabin Karp

V U A T S

$$\underline{5} + 1 = 6$$

T S

$$2 + 3 = 5$$

1

Values

$$U = 1$$

$$T = 2$$

$$S = 3$$

$$A = 4$$

$$V = 5$$



Rabin Karp

V U A T S

$$1 + 4 = 5$$

Spurious Hit

T S

$$2 + 3 = 5$$

2

Values

$$U = 1$$

$$T = 2$$

$$S = 3$$

$$A = 4$$

$$V = 5$$



Rabin Karp

V U A T S
4 + 2 = 6

T S
2 + 3 = 5

3 Values

U = 1

T = 2

S = 3

A = 4

V = 5



Rabin Karp

V U A T S

4

Values

$$2 + 3 = 5$$

Matched !

T S

$$2 + 3 = 5$$

$$U = 1$$

$$T = 2$$

$$S = 3$$

$$A = 4$$

$$V = 5$$



SON