

COMPARISON OF THE PERFORMANCE OF RESNET-50 AND SHUFFLENET DEEP LEARNING ALGORITHMS IN CLASSIFICATION OF HAZELNUT FRUIT

Özgür Tomak^{1*}, Mehmet Cem Dikbaş², Sercan Külçü³

^{*1} Giresun University, Computer Engineering, Giresun, Türkiye

² Giresun University, Electrical and Electronics Engineering, Giresun, Türkiye

³ Giresun University, Computer Engineering, Giresun, Türkiye

<https://orcid.org/0000-0003-2993-6913>

<https://orcid.org/0000-0003-4525-7996>

<https://orcid.org/0000-0002-4871-709X>

ABSTRACT

The use of artificial intelligence in hazelnut fruit classification can be very useful in increasing efficiency and improving quality control processes. Our aim in this study is to propose a method for an automatic classification system that can be used in the classification of hazelnut fruit. Deep learning methods were examined in the process of analyzing hazelnut images by artificial intelligence and the performances of Resnet-50 and Shufflenet deep learning algorithms on the hazelnut fruit database were compared. ResNet-50 has 177 layers in total and corresponds to a 50-layer Residual network (ResNet). ShuffleNet is a convolutional neural network designed for devices with limited processing power and uses fewer resources by reducing the number of parameters and computational load. In the data used, there is one hazelnut in each image. These hazelnuts are divided into three classes as good and bad hazelnuts and inner hazelnuts. A data set was created using 519 bad hazelnuts, 535 good hazelnuts and 523 inner hazelnuts. A total of 15770 images were obtained with 10 images taken from different angles from each hazelnut. As a result of the analysis, ResNet-50 achieved 99.92% accuracy in training and 99.97% in the test phase. ShuffleNet achieved 99.79% accuracy in training and 99.94% in the test phase. Due to the importance of obtaining fast results in real-time analysis and the closeness of the analysis results, ShuffleNet deep learning algorithm is recommended as a better option in the classification of Hazelnut fruit.

Keywords: Hazelnut, Classification, Deep Learning, Resnet-50, Shufflenet

FINDIK MEYVESİNİN SINIFLANDIRILMASINDA RESNET-50 VE SHUFFLENET DERİN ÖĞRENME ALGORİTMALARININ PERFORMANSININ KARŞILAŞTIRILMASI

Öz

Fındık meyve sınıflandırmasında yapay zekanın kullanımı verimliliği artırmada ve kalite kontrol süreçlerini iyileştirmede oldukça faydalı olabilir. Bu çalışmadaki amacımız fındık meyvelerinin sınıflandırılmasında kullanılabilecek otomatik bir sınıflandırma sistemi için bir yöntem önermektir. Fındık görüntülerinin yapay zeka ile analiz edilmesi sürecinde derin öğrenme yöntemleri incelenmiş ve Resnet-50 ve Shufflenet derin öğrenme algoritmalarının fındık meyve veri tabanı üzerindeki performansları karşılaştırılmıştır. ResNet-50 toplamda 177 katmana sahip olup 50 katmanlı bir Residual Network'e (ResNet) karşılık gelmektedir. ShuffleNet, sınırlı işlem gücüne sahip cihazlar için tasarlanmış bir evrişimli sinir ağı olup parametre sayısını ve hesaplama yükünü azaltarak daha az kaynak kullanmaktadır. Kullanılan verilerde her görüntüde bir adet fındık bulunmaktadır. Bu fındıklar iyi ve kötü fındıklar ile iç fındıklar olmak üzere üç sınıfa ayrılmıştır. 519 adet kötü fındık, 535 adet iyi fındık ve 523 adet iç fındık kullanılarak bir veri seti oluşturulmuştur. Her fındıktan farklı açılardan alınan 10 görüntü ile toplam 15770 görüntü elde edildi. Analiz sonucunda ResNet-50 eğitimde %99,92, test aşamasında ise %99,97 doğruluk elde etti. ShuffleNet eğitimde %99,79, test aşamasında ise %99,94 doğruluk elde etti. Gerçek zamanlı analizde hızlı sonuç elde etmenin önemi ve analiz sonuçlarının yakınlığı nedeniyle ShuffleNet derin öğrenme algoritması Fındık meyvesinin sınıflandırılmasında daha iyi bir seçenek olarak önerilmektedir.

Anahtar Kelimeler: Fındık, Sınıflandırma, Derin Öğrenme, Resnet-50, Shufflenet

Giriş

Yapay zekâ, fındıkların görüntülerini analiz ederek kalite, boyut ve renk gibi özelliklerine göre sınıflandırma yapabilir. Bu, elle yapılan sınıflandırmalara göre daha hızlı ve doğru sonuçlar elde edilmesini sağlayabilir. Makine öğrenimi algoritmaları kullanılarak ve fındık üretiminde toplanan veriler analiz edilerek, belirli koşullar altında yetişen en iyi ürünler belirlenebilir. Bu, üreticiye hangi tür fındıkların hangi koşullarda daha iyi yetiştiğine ilişkin bilgiler sunabilir. Bitki hastalıklarını erken tespit etmede yapay zekâ kullanılabilir. Fındık ağaçlarının sağlık durumunu izleyerek, hastalıkların yayılmasını önlemeye yardımcı olabilir. Fındık toplama ve işleme süreçlerinde otomasyon sağlamak için yapay zekâ destekli cihazlar kullanılabilir. Bu, iş gücünü azaltır ve maliyetleri düşürebilir.

Evrişimsel sinir ağları, fındık meyvesinin sınıflandırılmasında etkili bir yöntem olarak kullanılabilir. Bu süreçte uygulanacak ilk adım, fındık meyvelerine ait bir veri seti oluşturmaktır. Toplanan verilerin temizlenmesi ve normalize edilmesiyle sınıflandırıcıdan daha iyi bir performans alabiliriz. Görüntü verileri için, boyutlandırma, keskinleştirme gibi görüntü işleme teknikleri uygulayabiliriz. Veri seti, eğitim ile test setleri şeklinde ayrılır. Eğitim setimiz, sinir ağının öğrenmesi amacıyla kullanılır ve test

seti modelimizin başarımını değerlendirmek amacıyla kullanılır. Eğitim sürecinde modelin başarımı sürekli olarak değerlendirilir. Eğitim tamamlandıktan sonra oluşturulan model fındık meyvelerini sınıflandırmak için kullanılabilir. Yeni veriler üzerinde modelin tahmin performansı ölçülerek, sonuçların doğruluğu değerlendirilir.

Fındık meyvelerini sınıflandırma alanında yapılmış çalışmalar incelersek, Bayrakdar ve ark., 2015, çalışmalarında görüntüler aracılığıyla 3 farklı fındık türünü(Tombul, sivri ve badem tipi) sınıflandırmışlardır. Tombul, sivri ve badem tipi fındık çeşitlerine ait görüntülerden çap, yarıçap, alan gibi şekil ve boyut özelliklerini kullanarak %84'lük bir doğruluk oranına ulaşmışlardır. (Bayrakdar ve ark., 2015)

Caner ve ark., 2020. çalışmalarında fındık meyvesini fotoğrafları aracılığıyla kabuğuyla birlikte sınıflandıran bir sistem geliştirmişlerdir. Tombul sivri ve kara fındık çeşitlerini makine öğrenmesi ve derin öğrenme yöntemlerini kullanarak sınıflandırmışlardır. Çalışmalarında Bagging yöntemi (Rastgele orman) kullanarak %83 ve DL4J (Derin öğrenme algoritması) kullanarak %71 sınıflandırma doğruluğu elde etmiştir. (Caner ve ark., 2020).

Keles ve Taner, 2021 çalışmalarında fındık çeşitlerini kategorize etmek için yapay sinir ağları ve ayırıcı analiz kullandılar. 11 fındık çeşidinin fiziksel, mekanik ve görsel özelliklerinin üç ana eksenini belirlendi. Fındık çeşitleri bağımlı değişkenler olarak ve fiziksel, mekanik ve optik özellik parametreleri bağımsız değişkenler olarak dahil edildi. Çok sayıda fındık çeşidini kategorize etmek için üç eksenin her biri için modeller yapıldı. Diskriminant Analizi ve Yapay Sinir Ağları sırayla X ekseninde %92,7 ile %89,1 ve Y ekseninde %92,7 ile %92,7 son olarak Z ekseninde %88,7 ile %86,8 sınıflandırma başarı oranına sahiptir. (Keles ve Taner, 2021)

Materyal ve Metot

Yapay zekânın fındık görüntülerini analiz etmesi sürecinde derin öğrenme yöntemleri incelenmiştir ve Resnet-50 ve Shufflenet derin öğrenme algoritmalarının fındık meyvesine ait veri tabanında performansları karşılaştırılmıştır.

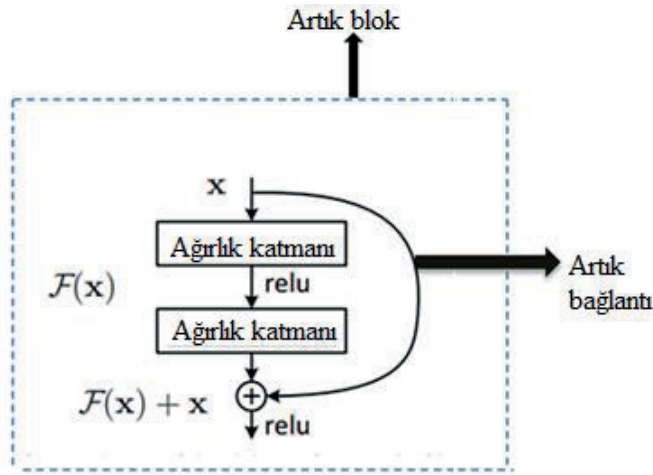
ResNet-50

ResNet-50, ImageNet veri tabanının (URL-1) bir alt kümesi üzerinde eğitilmiş ve 2015 yılında ImageNet Büyük Ölçekli Görsel Tanıma Yarışmasını kazanmış önceden eğitilmiş bir modeldir. Model bir milyondan fazla görüntü üzerinde eğitilmiştir, toplamda 177 katmana sahiptir ve 50 katmanlı bir Artık ağa (ResNet, Residual Network) karşılık gelir ve görüntüleri bin adet nesne kategorisine (örneğin kalem, klavye ve çok miktarda hayvan) sınıflandırabilir. Sinir ağının görüntü giriş boyutu 224x224'tür.

Klasik bir sinir ağında giriş, bir dizi evrimsel katman tarafından dönüştürülür ve ardından aktivasyon fonksiyonuna geçirilir. Artık bir ağda, bloğa giriş, bloğun çıktısına eklenerek artık bir bağlantı

oluşturulur. Artık blok $H(x)$ 'in çıkışı Denklem (1) ve Şekil 1'deki gibi gösterilebilir. (He ve ark., 2016) Artık bağlantı, artık blokların oluşturulmasına yardımcı olur. Artık bağlantı, artık bloğun girişinin evrimsel katman üzerinden atlanarak artık bloğun çıkışına eklenmesiyle oluşur. ResNet mimarileri, birden fazla artık bloğun bir araya getirilmesiyle oluşturulur. Her konvolüsyonel katmandan sonra uygulanan toplu normalizasyon, eğitim sırasında daha istikrarlı bir öğrenme süreci sağlar. Resnet mimarileri genellikle tam bağlı katmandan (fully connected layer) önceki son katman olarak Küresel Ortalama Havuzlamayı (Global average Pooling) kullanır. Küresel Ortalama Havuzlama tüm özellik haritasının kompakt bir temsiliyi sağlayarak, mekansal boyutları özellik haritası başına tek bir değere indirger.

$$H(x) = F(x) + x \quad (1)$$



Şekil 1. Artık Blok

Shufflenet

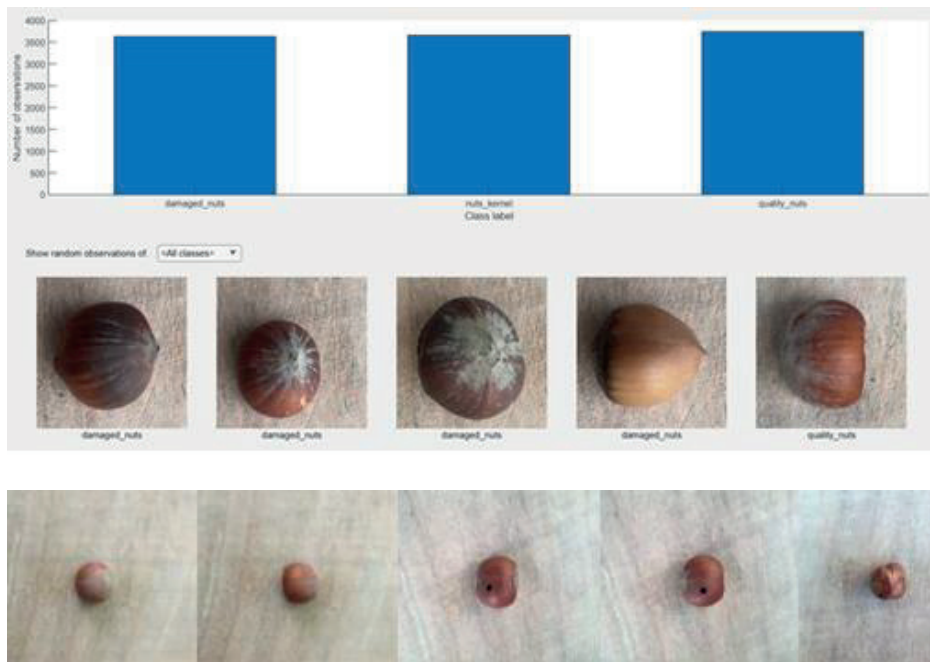
ShuffleNet, çok sınırlı işlem gücüne sahip mobil cihazlar için özel olarak tasarlanmış bir evrimsel sinir ağıdır. ShuffleNet, parametre sayısını ve hesaplama yükünü azaltarak daha az kaynak kullanır. Bu, onu mobil uygulamalar için ideal kılar. Mimari, doğruluğu korurken hesaplama maliyetini azaltmak için iki yeni işlem olan nokta bazlı grup evrimi ve kanal karıştırmayı kullanır. (Zhang ve ark., 2018) Temel yapı taşı olan ShuffleNet bloğu, derinlik yönlendirmeli ayrık (depthwise separable) konvolüsyonlar kullanır. Bu konvolüsyonlar, giriş özellik haritalarını daha küçük boyutlarda işler, böylece hesaplama verimliliğini artırır. Ağırlıkların karıştırılması (shuffle) işlemi, farklı özellik haritalarının bir araya getirilmesini sağlar. Bu, ağına daha iyi genel performans göstermesine yardımcı olur.

ShuffleNet biriminde ilk ve ikinci 1×1 evrişimler grup evrişimleriyle değiştirilir. İlk 1×1 evrişimden sonra bir kanal karıştırması uygulanır. Adım sayısı=2 ile ShuffleNet biriminde kısayol yoluna 3×3 ortalama havuzlama eklenir. Ayrıca, eleman bazında ekleme, kanal boyutunu çok az ek hesaplama maliyetiyle genişletmeyi kolaylaştıran kanal birleştirme ile değiştirilir. ShuffleNet daha geniş özellik haritaları kullanabilir. Bu küçük ağlar için önemlidir, çünkü küçük ağlar genellikle bilgileri işlemek için yeterli sayıda kanala sahip değildir.

Veri Seti

Kullanılan veriler, 12 megapiksel çözünürlüğe sahip arka kamera ile elde edilmiştir. Görüntüler platform yardımıyla 3024 x 3024 piksel çözünürlükte çekilmiştir. Her görüntüde bir tane fındık bulunur. Bu fındıklar, bir uzman tarafından kötü fındıklar, iyi fındıklar, iç fındıklar şeklinde üç sınıfa ayrılmıştır. 519 adet kötü fındık, 535 adet iyi fındık ve 523 adet iç fındık kullanılarak bir veri seti oluşturulmuştur. Her bir fındıktan alınan farklı açılarda 10 görüntü ile toplam 15770 adet görüntü elde edilmiştir.


Görüntüler önce işlenerek önce 1000 x 1000 piksel boyutuna kırılmış sonra 224 x 224 piksele yeniden boyutlandırılmıştır. Kullanılan fındıklardan bazılarının ait görüntüler Şekil 2'de verilmiştir.(Güneş, 2022)




Şekil 2. Fındık veri tabanı

Bulgular ve Tartışma

Veri tabanı üç farklı sınıfa sahiptir ve toplamda 15770 adet görüntüye sahiptir. Çalışmada derin öğrenme algoritmalarından ResNet-50 ve ShuffleNet kullanılmıştır. Çalışma ortamı olarak MATLAB kullanılmıştır. Veri seti rastgele karıştırılarak % 30'u eğitim kalan kısım test amacıyla kullanılmıştır. Algoritmaların fındık meyvesi veri tabanındaki eğitim ve test doğrulukları karşılaştırılmıştır. Sonuçta ResNet-50 eğitimde % 99.92, test aşamasında % 99.97 doğruluğa ulaşmıştır. Şekil 3'de doğruluk grafiği verilmiştir. ShuffleNet eğitimde % 99.79, test aşamasında % 99.94 doğruluğa ulaşmıştır. Şekil 4'de doğruluk grafiği verilmiştir.



Şekil 3. ResNet-50 Doğruluk grafiği



Şekil 4. ShuffleNet Doğruluk grafiği

Çalışmada algoritmaların performansını ölçmekte karmaşıklık matrisi (Confusion Matrix) kullanılmıştır ve doğruluk, hassaslık, özgünlük, F1 skor gibi ölçütlere ulaşılmıştır. Burada TP (True Positive) gerçek pozitif değeri, FP (False positive) yanlış pozitif değeri, TN (True negative) gerçek negatif değeri ve FN (False negative) yanlış negatif değeri ifade etmektedir. (Tomak, 2019) Karmaşıklık matrisi tablo 1’de ve doğruluk, hassaslık, özgünlük, F1-skori matematiksel ifadeleri Denklem 2-5’de verilmiştir. Şekil 5’de ResNet-50’e ait karmaşıklık matrisi verilmiştir. Şekil 6’da ShuffleNet’e ait karmaşıklık matrisi verilmiştir. Karmaşıklık matrisine göre ResNet-50, 0.9997 hassaslık, 1 özgünlük, 0.9999 F1-skori değerine ve Shufflenet 0.9997 hassaslık, 0.9994 özgünlük, 0.9997 F1-skori değerine sahiptir.

Tablo 1. Karmaşıklık matrisi.

		Tahmini durum	
		Pozitif	Negatif
Gerçek Durum	Pozitif	TP, Gerçek Pozitif	FN, Yanlış Negatif
	Negatif	FP, Yanlış Pozitif	TN, Gerçek Negatif

$$Doğruluk = \frac{TP+TN}{TP+FP+FN+TN} \quad (2)$$

$$Hassaslık = \frac{TP}{TP+FN} \quad (3)$$

$$Özgünlük = \frac{TN}{TN+FP} \quad (4)$$

$$F1 \text{ skor} = 2 * \frac{Hassaslık * Özgünlük}{Hassaslık + Özgünlük} \quad (5)$$

		Confusion Matrix			
Output Class	damaged _n uts	3633 32.9%	1 0.0%	0 0.0%	100.0% 0.0%
	nuts _k ermel	0 0.0%	3658 33.1%	0 0.0%	100% 0.0%
	quality _n uts	0 0.0%	2 0.0%	3745 33.9%	99.9% 0.1%
		100% 0.0%	99.9% 0.1%	100% 0.0%	100.0% 0.0%
		damaged _n uts	nuts _k ermel	quality _n uts	
		Target Class			

Şekil 5. ResNet-50 karmaşıklık matrisi

		Confusion Matrix			
Output Class	damaged _n uts	3632 32.9%	1 0.0%	1 0.0%	99.9% 0.1%
	nuts _k ermel	0 0.0%	3657 33.1%	1 0.0%	100.0% 0.0%
	quality _n uts	1 0.0%	3 0.0%	3743 33.9%	99.9% 0.1%
		100.0% 0.0%	99.9% 0.1%	99.9% 0.1%	99.9% 0.1%
		damaged _n uts	nuts _k ermel	quality _n uts	
		Target Class			

Şekil 6. Shufflenet karmaşıklık matrisi

Sonuçlar ve Öneriler

Fındık meyvesinin depolaması sürecinden önce fındıklar temizlenmelidir. Temizleme sürecinde kötü fındık veya iç fındık bulunursa ayrılmalıdır. Kötü fındık ayrılmazsa randımanı düşük gelir. İç fındık temizlenmezse depolama süresinde bu fındıklar bozulabilir. Bu işlem için kullanılabilmesi muhtemel iki derin öğrenme algoritması ResNet-50 ve Shufflenet karşılaştırılmıştır. Analizler sonucunda ResNet-50 eğitimde % 99.92, test aşamasında % 99.97 doğruluğa ulaşmıştır. ShuffleNet eğitimde % 99.79, test aşamasında % 99.94 doğruluğa ulaşmıştır. Karmaşıklık matrislerine bakarsak göre ResNet-50, 0.9997 hassaslık, 1 özgünlük, 0.9999 F1-skor değerine ve Shufflenet 0.9997 hassaslık, 0.9994 özgünlük, 0.9997 F1-skor değerine sahiptir. ResNet-50 bu analizlerde çok ufak bir fark da olsa daha iyi sonuçlar verdi. Ama kullandığımız veri tabanındaki sınıflandırma sürecinde ShuffleNet derin öğrenme algoritmasının, ResNet-50 derin öğrenme algoritmasına göre daha hızlı olduğunu gördük. Gerçek zamanlı analizlerde hızlı sonuçlar elde etmenin önemi ve analiz sonuçlarının yakın olmasından dolayı ShuffleNet derin öğrenme algoritması Fındık meyvesinin sınıflandırılmasında daha iyi bir seçenek olarak önerilmektedir.

REFERENCES

- Bayrakdar, S., Çomak, B., Başol, D., & Yücedag, İ. (2015, May). Determination of type and quality of hazelnut using image processing techniques. In 2015 23rd Signal Processing and Communications Applications Conference (SIU) (pp. 616-619). IEEE.
- Caner, K. O. C., Gerdan, D., Eminoğlu, M. B., Yegül, U., Bulent, K. O. C., & Vatandaş, M. (2020). Classification of hazelnut cultivars: comparison of DL4J and ensemble learning algorithms. *Notulae Botanicae Horti Agrobotanici Cluj-Napoca*, 48(4), 2316-2327.
- Güneş, Engin (2022), "Hazelnuts", Mendeley Data, V2, doi: 10.17632/dvxx6kst3f.2
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).
- Keles, O., & Taner, A. (2021). Classification of hazelnut varieties by using artificial neural network and discriminant analysis. *Spanish Journal of Agricultural Research*, 19(4), e0211-e0211.
- Tomak, Ö. (2019). Elektrokardiyografi Sinyallerinde Deneysel Mod Ayırıştırma Ve Geliştirilmiş Karar Ağaçları Kullanarak Aritmi Tespiti. *Karadeniz Fen Bilimleri Dergisi*, 9(1), 103-110.
- URL-1: ImageNet. <http://www.image-net.org>. (Erişim Tarihi: 7 Ekim 2024).
- Zhang, X., Zhou, X., Lin, M., & Sun, J. (2018). Shufflenet: An extremely efficient convolutional neural network for mobile devices. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 6848-6856).